

mE

# ¿Qué hace valiosa a una startup tecnológica?

Análisis exploratorio y predicción de la valuación

Trabajo final de Ciencia de Datos

**25.000 startups globales · dataset sintético**

10 dominios

10 países


6 etapas

Aclaración: El dataset es sintético y se utilizó con fines académicos. Por lo tanto, permite evaluar la metodología, pero los resultados no deben generalizarse directamente al mercado real.

*"...advanced real-world synthetic dataset tracking the evolution of the global technology ecosystem..."*

<https://www.kaggle.com/datasets/saitejabandaruin/global-tech-startups-pipeline>

Grupo 10 - Agüero Luciana | Gutierrez Sídoli Priscila | Maldonado Vanesa | Paredes Silvina



# Pregunta y objetivo

02

¿Qué factores financieros, tecnológicos y geográficos están asociados con la valuación de una Startup y qué tan bien podemos predecirla mediante ML para asesorar inversionistas utilizando el modelo como herramienta de apoyo?

1 · Asociación

2 · Predicción

Qué factores se relacionan con la valuación y qué tan bien podemos estimarla.

## Objetivo

Identificar qué hace valiosa a una startup tecnológica y qué tan bien podemos predecir su valuación mediante datos observables.

## Relevancia

Los resultados pueden ayudar a **inversores y emprendedores** a reconocer patrones en empresas con diferentes perfiles.

## Conclusión

El trabajo combina análisis descriptivo y predicción: buscamos patrones útiles sin interpretar las asociaciones como relaciones causales.

# Dataset y calidad de datos

03

Cobertura amplia para comparar perfiles tecnológicos, geográficos y financieros

**25.000**

startups, una por fila

**17**

variables originales

**10**

dominios tecnológicos · 10  
países

**29**

ciudades

## Calidad

**0**

filas duplicadas

**0**

valores faltantes

**2012-2025**

año de fundación de la startup

6 etapas de funding

**Target: Valuation\_USD\_Millions**

Company\_ID se excluye del modelado porque solo identifica registros.

Los faltantes están concentrados en una sola variable; no hay registros duplicados.

### Conclusión

La base es consistente para el análisis: 25.000 registros, sin duplicados y con faltantes localizados que pueden tratarse mediante imputación.

# Variables y enfoque analítico

04

Integramos variables de negocio, finanzas, escala y contexto dentro de un único flujo reproducible

## Información disponible

|                 |                                             |
|-----------------|---------------------------------------------|
| <b>Negocio</b>  | Dominio, etapa, inversor y adquisición      |
| <b>Finanzas</b> | Funding, valuación, ARR, burn rate y runway |
| <b>Escala</b>   | Headcount y despidos                        |
| <b>Contexto</b> | País, ciudad, antigüedad y adopción de IA   |

## Proceso

01

Calidad y EDA

02

Feature engineering

03

Modelos de regresión

04

**Validación**

Target: valuación

4 bloques de predictores

MAE · RMSE ·  
R<sup>2</sup>

### Conclusión


El proceso conecta calidad, transformación y modelado bajo el mismo pipeline, facilitando una comparación consistente entre modelos.

# Concentración por dominio y país


05

Distribución de las 25.000 startups: la muestra no está repartida de manera uniforme

## Dominio tecnológico



## País




### Conclusión

Generative AI (20,2%) y EE. UU. (44,7%) tienen un peso dominante; esta concentración debe considerarse al interpretar los resultados.

# La muestra se concentra en etapas iniciales

06

La distribución por Funding Stage está sesgada hacia empresas tempranas



**59,8%**

está en Seed o Series A

**79,9%**

está entre Seed y Series B

**8,2%**

está en Pre-IPO o Post-IPO

## Conclusión


El dataset representa principalmente startups en etapas iniciales; las etapas maduras tienen mucha menor presencia en la muestra.

# Valuación por etapa de financiamiento

07


La mediana de valuación aumenta de forma sostenida a medida que avanza la etapa de financiamiento

Mediana: menos sensible a valores extremos que el promedio



113x

mediana Post-IPO frente a Seed



Seed

USD 25,51 M

Post-IPO

USD 2.881,10 M


## Conclusión

La etapa de financiamiento muestra el patrón descriptivo más claro: Post-IPO tiene una mediana 113x mayor que Seed. Es asociación, no causalidad.

# El dominio diferencia más que el país

08

La variación entre dominios tecnológicos es mucho mayor que la observada entre países



## Valuación mediana

Generative AI

**USD 144,88 M**

SpaceTech

**USD 115,55 M**

**2,69×**

Generative AI vs. ClimateTech

**1,32×**

India vs. Singapur por mediana


### Conclusión

En este dataset, el dominio tecnológico separa más la valuación que el país; la ubicación geográfica muestra diferencias bastante menores.

# Correlaciones con la valuación

09

Correlación de Spearman · asociación monotónica, no causalidad



**0,960**

Funding vs. valuación

**0,943**

ARR vs. valuación

**0,812**

Burn rate vs. valuación

Año de fundación  $\approx 0$


## Conclusión

Funding y ARR muestran la asociación más fuerte con la valuación; el año de fundación casi no se relaciona.

# Diseño del modelo predictivo

10

Un mismo pipeline para preparar, entrenar y comparar los modelos en condiciones equivalentes



**Variable objetivo**

**log(Valuación)**

Luego se vuelve a USD millones para interpretar los errores.

**Predictores**

Variables financieras, tecnológicas y geográficas disponibles antes de la predicción

Se excluye Company\_ID y cualquier variable que contenga el target para evitar leakage.


**Conclusión**

La transformación logarítmica reduce el peso de valuaciones extremas y permite una comparación más estable entre modelos.

# Gradient Boosting: mejor $R^2$ log

11

Comparación de modelos sobre la variable objetivo transformada



Criterio principal:  $R^2$  log

**0,973**

$R^2$  sobre log(valuación)

**USD 111 M**

MAE en escala original

**USD 768 M**

RMSE en escala original


## Conclusión

Gradient Boosting lidera en  $R^2$  log y MAE. Random Forest queda muy cerca y obtiene mejor RMSE y  $R^2$  en escala original.

# La validación cruzada confirma estabilidad

12

5 particiones · cada registro se usa una vez para validar el modelo




**0,9735**

R² promedio en 5 particiones

**0,0005**

Desvío entre particiones

Real vs. predicho · ideal: puntos cercanos a la diagonal




## Conclusión

Los cinco R² son casi idénticos (0,9730–0,9742): el desempeño no depende de una única división de los datos.

# Análisis de errores del modelo

Gradient Boosting · test set · residuos en escala logarítmica



## Lectura del gráfico

La mayor parte de los residuos se concentra cerca de cero: el modelo acierta razonablemente bien en la mayoría de los casos.

**Residuo = real – predicho**

Positivo: subestimación · Negativo: sobreestimación

El error crece con el tamaño de la startup  
USD 8 M → 54 M → 228 M → 1.235 M

## Resumen de errores

**USD 12 M**

Error absoluto mediano

**USD 111 M**

MAE promedio

**USD 197 M**

90% de los errores ≤ este valor

**USD 46.047 M**

Mayor error absoluto · startup Post-IPO

### Conclusión

El modelo funciona bien para la mayoría de los casos, pero las valuaciones extremas generan outliers que elevan fuertemente el error.

# Conclusiones

15

Resumen final de los principales hallazgos de la notebook

1

## Hallazgos descriptivos

### Generative AI

mayor mediana por dominio

India · mayor mediana por país

Post-IPO presenta la mayor mediana de valuación entre las etapas de financiamiento.

2

## Relaciones más significativas

$\rho$  0,960 · 0,943

Funding · ARR

Correlaciones de Spearman

Funding y ARR son las variables con mayor asociación con la valuación dentro del dataset.

3

## Mejor modelo: Gradient Boosting

$R^2$  log 0,973

$R^2$  original 0,874

MAE USD 111 M · RMSE USD 768 M

El modelo logra alta capacidad predictiva, aunque los errores crecen en valuaciones extremas.

## Conclusión general

**En este dataset, la valuación se relaciona principalmente con el nivel de financiamiento, el ARR y la etapa de madurez. Gradient Boosting captura bien estos patrones y muestra un desempeño estable.**

Los resultados muestran asociaciones y capacidad predictiva; no implican causalidad. Al tratarse de un dataset sintético, no deben generalizarse directamente al mercado real.

¿Preguntas?